



世界杯比分预测器 · 测算逻辑白皮书

Dixon-Coles 双泊松模型 × 蒙特卡洛赛事模拟 × 贝叶斯不确定性量化

—— 与高盛（Goldman Sachs）大赛预测方法论的对比分析

生成日期：2026-06-07 | 修订：2026-07-07 (v4: 夺冠蒙特卡洛对真实赛果实时条件化) | 数据源：martj42 国际赛果 (1872-2026) + ESPN 实时层 | 引擎经样本外回测验证

一句话概括：本系统把"预测一场球赛"拆成两层——先用 Dixon-Coles 双泊松回归从 150 年真实国际比赛数据里学出每支球队的进攻/防守强度，再用 蒙特卡洛模拟 (5k-10k 次/届) 把单场概率滚成整届赛事的出线/夺冠概率。所有"优化"都必须通过样本外回测 (RPS / LogLoss / 命中率) 用数字证明更好才采纳，绝不凭感觉。本届 2026 世界杯小组赛打满 72 场后，赛果命中率 62.5% 已收敛到样本外真值 (约 59.5%) 一线——见 §2.3 的开赛期实测验证。

一、设计哲学：为什么这么建模

足球比赛的本质是低频泊松事件（进球稀少且近似独立），结果由两队的相对攻防实力加上不可消除的随机性共同决定。因此我们刻意选择一个可解释、可回测、训练秒级的统计模型，而非黑箱大模型：

- 可解释：每支球队两个数字（进攻、防守），任何预测都能追溯到这两个系数，便于发现数据问题。
- 可回测：模型轻，可在多个历史时段反复"只用过去预测未来"，量化真实预测力。
- 诚实的不确定性：用蒙特卡洛与贝叶斯两条腿，分别量化"赛事随机性"和"评级估计误差"。

二、我们的测算逻辑（五层）



2.1 数据层：不是所有比赛都一样重要

原始数据为 martj42 公开数据集的 `results.csv` (约 4.9 万场国际比赛, 1872 年至今)。关键在于加权——把每场比赛拆成"主队视角 / 客队视角"两行长表，每行配一个权重：

$$\text{weight} = \text{时间衰减} \times \text{赛事强度}$$
$$= 0.5^{(\text{比赛年龄}_\text{天} / \text{half_life})} \times (\text{友谊赛 } 0.5 / \text{正式赛 } 1.0)$$

- 时间衰减：半衰期 `half_life=730` 天 (≈2 年)。一年前的比赛权重约剩 71%，两年前剩一半，五年前降到约 1/5——反映"国家队阵容和状态会换血"，但不至于把稍早的证据丢得太快。
- 赛事强度：友谊赛队伍不齐、强度低，权重下调到 0.5。
- 中立场处理：世界杯多为中立场，主场优势只给真正的东道主（中立场两边 `home=0`）。

- **样本过滤**：最多回溯 16 年；出场不足 12 场的球队剔除（拟合不稳）。

经时间加权后，4.9 万场的“有效权重和”约 4957（半衰期 730 天口径）——这意味着真正主导评级的是最近两三年的比赛。这个数字在第 2.5 节解释可信区间为何偏宽时还会用到。

⚠ 重大修正 (2026-06)：half_life 从 240 改为 730。早期版本用 half_life=240 并自称"240 天最优"，后来发现回测训练帧没有剔除 cutoff 之后的比赛（负年龄样本权重 $0.5^{(\text{负数})} > 1$ ），造成时间泄漏——旧的绝对回测数字（RPS 0.144x）全部被未来数据美化过。修复（剔除未来场）后重扫半衰期，730 天才是诚实口径下的样本外最优，旧的"240 最优"是泄漏伪影（短半衰期会放大被泄漏未来场的超额权重）。详见 §2.3。

2.2 核心模型：Dixon-Coles 双泊松回归

每队单场进球数建模为泊松分布，进球期望 λ 由对数线性模型给出（Maher 1982 / Dixon-Coles 1997 的经典框架）：

$$\begin{aligned} \log \lambda_{\text{主}} &= \text{截距} + \text{主场优势} \cdot (\text{非中立}) + \text{进攻}[\text{主}] + \text{失球}[\text{客}] \\ \log \lambda_{\text{客}} &= \text{截距} + \text{进攻}[\text{客}] + \text{失球}[\text{主}] \end{aligned}$$

用 statsmodels 的 Poisson GLM 拟合（凸优化，秒级收敛），把上面的时间衰减权重作为 freq_weights 喂入。每支球队最终得到两个系数：进攻强度（越高进球越多）与失球倾向（越负防守越好）。

Dixon-Coles 低分修正

独立双泊松会系统性低估 0-0、1-1 这类低比分平局（现实中两队都谨慎时强相关）。我们引入一个相关参数 ρ ，只修正 (0,0)(0,1)(1,0)(1,1) 四个低分格，用一维优化单独估计：

$$\begin{aligned} \tau(0,0) &= 1 - \lambda\mu\rho & \tau(0,1) &= 1 + \lambda\rho \\ \tau(1,0) &= 1 + \mu\rho & \tau(1,1) &= 1 - \rho \end{aligned}$$

最终输出一个 11x11 的比分概率矩阵（0-10 球），归一化后即可读出：最可能比分、胜/平/负概率、期望进球 xG。

2.3 参数标定：用回测说话，不靠拍脑袋

这是本系统的纪律核心。任何参数改动都要在样本外回测里用数字证明更好。回测方法：选若干历史 cutoff，只用 cutoff 之前的数据训练，预测之后 270 天的真实比赛，比较预测的胜平负概率与真实结果。

指标	含义	方向
RPS (Ranked Probability Score)	有序三分类（主胜/平/客胜）的概率打分，足球预测金标准	越低越好
LogLoss	对数损失，重罚"自信却错"的预测	越低越好
命中率	最大概率方向是否押中	越高越好

实测证据（修复时间泄漏后的诚实口径；4 个 cutoff：2023-06 / 2024-03 / 2024-11 / 2025-08，horizon = 270 天，合计 n = 3376 场）：

half_life 配置	RPS ↓	说明
240 天 (旧"最优")	0.1702	泄漏伪影；短半衰期放大被泄漏未来场的超额权重
547 天	0.1667	
730 天 (采纳)	0.1662	取最近两 cutoff 最优、最贴近 2026 部署情形
1095 天	0.1660	平底盆地，与 730 实质并列
1460 天	0.1662	

730—1460 天是一片"平底盆地" (RPS 几乎并列)，我们取其中最近两个 cutoff 表现最优、也最贴近部署情形的 730 天。注意：修复时间泄漏后所有绝对 RPS 都比旧版 (0.144x) 高一截，因为旧数字本就被未来数据美化过——这正是诚实口径的代价，也是纪律的体现。

同样的方法论让我们用数字否决了多个看似合理的"优化" (默认全部关闭)：

- **已否决** 身价先验：把评级向 Transfermarkt 阵容身价收缩——回测 RPS 无改善 (国家队样本本就够大)，身价数值仍在 UI 展示。
- **已否决** Elo (替代 / 集成 / 作 GLM 外生特征)：把 Elo 差直接加进 $\log \lambda$ 也试过，RPS +0.0006 更差——全套攻防 dummy 下 Elo 差冗余。
- **已否决** 赛事强度分级加权：把"友谊 0.5 / 正式 1.0"细化为多级权重，回测全部更差 (抬大赛权重 = 砍有效样本、升方差)。
- **已否决** 负二项过离散：扣实力后残差已近 Poisson， $\alpha > 0$ 单调更差。
- **已否决** Isotonic / Platt 后校准：模型训练集 ECE 仅 1.06%，本就够校准，后校准只会过拟合。

开赛期实测验证 (2026 世界杯)：命中率正在趋近真值

回测是"用过去预测过去"，而开赛期提供了真正的前瞻验证：每场预测在开球前冻结存证，赛后逐场核对，绝不事后修改。小组赛打满 72 场后：

阶段	样本 n	赛果命中率	95% 置信区间
开赛初期	8	37.5%	[13.7%, 69.4%]
中段	36	55.6%	[39.6%, 70.5%]
小组赛收官	72	62.5%	[51.0%, 72.8%]
样本外回测真值	2420	≈59.5%	—

关键在于：8 → 36 → 72 场，命中率 37.5% → 55.6% → 62.5%，置信区间始终覆盖 59.5% 这个真值——在统计意义上它们一直是同一个数。命中率的爬升不是模型变强，而是样本变多后的均值回归；打满整个小组赛后稳定落在真值一线，引擎自修复时间泄漏后再没动过，这次收敛恰恰是它稳定、有效的证据。

- **决胜场 (非五五开)** 命中约 73% (高把握 30 场中 22、中把握 23 场中 17)；而 20 场平局只押中 1 场是结构性丢失——取概率最大项时几乎不会输出"平局"，这是所有概率模型的共同天花板，并非缺陷。硬币局 (三方接近) 仅 31.6%，也正是该最不确定的那一档。
- **RPS 0.1516** (72 场样本外冻结口径)，与回测基线同量级；平均赋实际结果概率 47.8%。本届概率延续诚实校准。

2026-06 优化 sprint：5 个杠杆，全部被回测否决

打满 36 场后做了一次多 agent 优化 sprint，想再从引擎里榨出一点。每个杠杆都用防泄漏 fresh 模型 + 训练/留出拆分 + 对抗验证检验，采纳门槛=池化 RPS 改善 > 0.0008 且最近 cutoff 不变差。结果五个全部诚实否决：

试过的杠杆	回测结论
平局决策规则	argmax 已是命中率最优；增益在轮换留出集上无法泛化
中立场名义主场倾斜	发现真实偏差（主队槽位被低估 +2.24pp），但仅 +0.0002 RPS（门槛 1/4）、窄峰
Dixon-Coles ρ 近期性重拟	+0.000008 RPS——惰性杠杆，低分结构跨时代稳定
分洲差异化半衰期	噪声（-0.00001 RPS），平底盆地上加自由度只抬方差
本届重新校准	本就已校准（见上），重校准只会过拟合

一个都没采纳，而这正是正确结果。命中率与 RPS 已贴近双泊松模型在本数据上的信息上限——剩余误差是结构性的（平局盲区）加小样本噪声，而非可修复的系统偏差。

2026-06 续 sprint：净胜球分布校准 + 淘汰赛阶段效应（更严的三道闸，仍全否决）

小组赛打满后又做了一轮，把"诚实纪律"加码成三道硬闸：① RPS/LogLoss 不变差 且 离散比回归 1 且 全档净胜球校准误差缩小（看全分布而非两点，专防"挪中间补两端"的伪改善）；② 防过冲（离散比须落 [0.95,1.05] 且邻域稳）；③ 时序留出（旧赛事选参数、新赛事冻结重测，防过拟合）。

- 先诊断** 净胜球分布欠离散：样本外 264 场世界杯正赛上，实际净胜球方差 / 模型隐含方差 = 1.204（模型方差偏小约 20%），平局格被高估、大比分尾部偏瘦——一张可证伪的"病灶地图"。
- 已否决** 负二项过离散 (nb_alpha)：调宽进球方差确实把离散比拉回 1、补了尾部，但 RPS/LogLoss/全档校准误差全部变差——是"拿准确度换单一矩"，闸一即不过。这与上一版" $\alpha > 0$ 单调更差"一致，并用全档校准误差证伪了只看两点的伪改善。
- 已否决** Dixon-Coles ρ 缩放（治平局虚胖）：选参赛事上削平局令各项单调改善（闸一过），但 ρ 够不着方差（闸二不过），且留出集上方向反转（选参集平局虚胖 +7.1pp、留出集 -0.6pp 几乎没有，闸三不过）。关键发现："平局虚胖"不跨届泛化、是样本噪声而非稳定结构缺陷，没有可泛化的靶子可打。 λ 全程冻结（实测零漂移），属只缩放非重拟。
- 已否决** 淘汰赛"保守效应"（强强对话踢得更紧、进球更少）：90 分钟口径上确实显著（淘汰赛场均 2.50 vs 小组赛 2.77 进球、 $p \approx 0.04$ ；平局率 +7pp、 $p \approx 0.02$ ），但剔除球队强度后纯阶段乘子仅 0.93、置信区间跨 1、不显著 ($p \approx 0.16$) ——原始效应大半由"淘汰赛球队更强更接近"驱动，而引擎攻防评级已建模这部分，再叠会重复扣减。此负结论对结算口径稳健（90 分钟与含加时口径下纯阶段均不显著）。

又是一轮全否决，且这次用更严的三道闸 + 全分布校准 + 时序留出把门槛抬得更高。校准缺陷确实存在（欠离散、平局盲区），但没有一个修法能在留出集上泛化地证明更好——剩余误差是结构性的，强行修补只会过拟合。诚实的结论是：在这套国家队数据上不动 GLM 核心。

2.4 赛事蒙特卡洛模拟：从单场到夺冠

有了任意两队的比分概率，就能模拟整届世界杯。流程严格遵循 2026 官方赛制（12 组 $\times$ 4 队，32 队晋级含最佳第三名分配，官方淘汰赛括号槽位）：

- 小组赛：每场按比分概率分布随机抽样一个比分 $\rightarrow$ 算积分、净胜球、排名。
- 出线：每组前 2 + 成绩最好的 8 个第三名，按官方约束匹配到 R32 槽位。

3. **淘汰赛**：单场对阵按模型胜率推进，平局按热门方"点球"决出，直到冠军。
4. **重复 N 次**（默认 5000—10000）→ 统计每队的出线 / 八强 / 四强 / 决赛 / **夺冠概率**，并给出基于模拟的 95% 区间。

东道主主场优势（已建模）：模拟器早期全程按中立立场处理，漏了美 / 墨 / 加在本国城市比赛的主场优势。现按 `venues.json` 的"城市→东道主国"精确映射，仅当东道主在本国城市比赛时给 **+23% xG 主场加成**（与"真正中立场两边 home=0"正交）。实测把东道主出线率拉到 **美 51% / 墨 95% / 加 94%**。此修正只动模拟器 / 赛程层，**不影响 GLM 训练与回测口径**。

随赛事推进的实时条件化（2026-07 补全）：蒙特卡洛不是从"赛前一张白纸"反复模拟——**已踢的真实赛果被当作事实条件**：小组赛真实比分逐场固定进抽样，淘汰赛真实胜负按对阵自动套用（用户 what-if 假设优先于事实，便于反事实推演）。因此夺冠概率随每场完赛动态更新，**已被淘汰的球队夺冠概率恰好归零**（并在前端标注"已淘汰"），存活球队的概率则按"剩余赛程 + 当前括号位置"重新分配。贝叶斯夺冠可信区间（§2.5）复用同一模拟器，同步继承此口径。

系统还提供**确定性投影**（project）：把已踢的真实赛果当事实锁定，未踢的取模型"最可能走势"，实时画出当前最可能的官方括号与冠军——支持用户改小组赛比分 / 录入或假设淘汰赛结果做 what-if，括号与夺冠概率即时重算。

2.5 贝叶斯分层评级：诚实回答"我们到底多确定"

蒙特卡洛量化的是**赛事随机性**，但还有一层不确定性被忽略了：**评级本身的估计误差**（数据有限，我们对"某队到底多强"并不确定）。为此我们用 PyMC 搭了一个分层贝叶斯双泊松模型作为补充视图：

- 同样的加权泊松似然，但对攻防系数施加**分层正态先验**（部分汇合 partial pooling，非中心化参数化），NUTS 采样 ≈ 15 秒。
- 输出每队净实力的**后验分布**，从而得到 **94% 可信区间**。

关键守则：贝叶斯评级是**不确定性补充视图**，**不替换预测引擎**。预测与模拟仍由经回测验证的 Dixon-Coles 引擎驱动，未违反"改模型必须回测证明"的铁律。由于分层收缩 + 时间加权后有效样本仅 ~ 1519 ，可信区间普遍较宽且互相重叠——这是对"近 8 个月数据下顶尖球队统计上难分高下"的**诚实表达**，而非模型缺陷。

2.6 工程闭环：让预测随真实世界更新

实时赛果驱动

已踢的世界杯比赛=事实（蓝色锁定），其余按模型预测。一键"刷新真实赛果"拉取最新数据，并用**新数据重训评级**（自动 refit， ≈ 9 秒）。

淘汰赛自动套入

已踢淘汰赛赛果按**对阵顺序无关**自动套进括号；平局的**点球胜者**查 shootouts 数据，解决官方比分库不记点球胜者的痛点。

赛果持久化

用户录入/假设的赛果**原子写入磁盘**，刷新或重启都不丢。

本地化体验

队名中文+国旗、北京时间 $\leftrightarrow$ 场馆当地时间一键切换（104 场场馆时区经维基逐场核对）。

开赛前新增的"只读旁路层"（绝不回灌引擎）

开赛后陆续加了若干能力，**全部是只读旁路、严格隔离**，绝不写训练数据、绝不碰 GLM/回测口径（项目内称"5 套算法隔离红线"）：

In-play 实时胜平负

赛中把赛前 λ 按剩余时间缩放、与当前比分做泊松卷积，给出"从现状到终场"的胜平负，随每个进球和分钟跳动。

预测验证账本

每场预测**开球前冻结存证**、赛后逐场打分（按把握分桶、标注冷门）——拿数字逼自己诚实，账本一旦写入只读。

夺冠 90% 可信区间

用分层贝叶斯后验抽样整套替换 DC 系数驱动蒙特卡洛，给夺冠概率配可信区间；新赛果后后台自动重算。

市场 / CLV 诚实层

模型 vs 博彩闭盘线 + 闭盘线价值检验；**无显著正 CLV 就不显示任何价值/注码**——做检验，不做下注诱导。

市场机制解读

用 Shin 法把盘口去抽水还原成真实隐含概率，并画"模型 vs 市场"分歧地图；每条分歧**强制挂"本模型 CLV<0、打不赢市场"先验**——纯描述性认知，零下注指令。

竞彩复盘

手动录入让球盘口（90 分钟结算口径）做"模型 / 市场 / 我"的单场三方对账；红线在数据结构层锁死——**绝不聚合成胜率 / 盈亏 / 行动处方**，定位是认清差距，不是找下注优势。

这些层为产品体验服务，但数据单向不回灌：预测与夺冠概率始终由经回测验证的 Dixon-Coles 引擎驱动，确保白皮书全篇的回测纪律不被旁路能力稀释。

三、高盛（Goldman Sachs）的测算逻辑

高盛自 2010 年起发布《The World Cup and Economics》系列研究报告（由其 Global Investment Research 团队撰写）。下述事实主要取自 2018 与 2026 两版官方报告 PDF 原文，2022 细节取自 2026 报告中的官方回测段，2014 以报告转述为准。

一个反直觉但有据可查的事实：高盛只有 2018 一届真正用了机器学习集成（随机森林 + 贝叶斯岭回归 + Lasso + 梯度提升，20 万模型、100 万次模拟，自评比旧泊松回归准 5 倍）。但 2014 / 2022 / 2026 三届都是以 Elo 为核心的泊松回归——高盛试过 ML 之后又回到了 Poisson。

3.1 模型与预测对象

与我们一致，高盛直接预测的是“每队每场进球数”，建模为泊松分布，胜平负 / 出线 / 夺冠概率全部由进球预测 + 模拟二次推导。2026 官方原文：“a regression model to predict the number of goals scored by a particular team ('team i') against a particular opponent ('team j')... described by a so-called 'Poisson' distribution.”

3.2 特征工程：领域知识是其最大差异点

这是高盛与纯统计模型最不同之处——它往进球回归里塞了大量足球领域变量（以 2026 版最详尽）：

特征类别	具体内容
Elo 评分差（主驱动）	赛前两队 Elo 之差；并随赛程递归更新。来源 eloratings.net。
得分天赋	进入欧洲顶级联赛前 50 射手榜的本队球员数，每队封顶 4 人（防极端值）。来源 Transfermarkt。
动量 Momentum	i 队最近 10 场正式赛进球数 + j 队最近 5 场正式赛失球数。
心态 Mentality	卫冕冠军下滑（winner's slump）、首次参赛超常发挥、对欧洲球队更难进球、足球强国“世界杯加成”——写进回归的哑变量。
地理 Geography	主场效应、首都到赛地距离、低海拔国家在高海拔球场罚分、本国与赛地温差罚分。

数据跨度：1978 年至今约 2 万场正式国际比赛；数据源 eloratings.net / Transfermarkt / FIFA。刻意排除友谊赛——2018 报告实证“加入友谊赛会让模型变差”。

3.3 模拟、输出与自评

- 蒙特卡洛：2026 用 5 万次抽样（2018 曾用 100 万次）；每场从该对阵的泊松分布随机抽比分。严格套官方 FIFA 平分规则，处理 48 队赛制下 R32 的 495 种可能配对；淘汰赛若抽到平局则“烧掉该抽样”（burning draws），机械性让均值略高方胜出，近似加时 / 点球。
- 输出：每场最可能比分点估计 + 蒙特卡洛各轮 / 夺冠概率分布；赛中逐比赛日滚动重算。 注意 不提供传统置信 / 可信区间。
- 诚实自评：2026 官方回测“预测净胜球 vs 实际净胜球的相关系数”——历届约 49%、2018 届 43%、2022 届 45%，自评“correlation remains modest”；并把自家概率与博彩盘口对标。

3.4 公开的"翻车"记录

高盛连续多届未押中冠军（且自己不回避）：

届次	高盛首选	实际冠军
2014	巴西夺冠（给东道主 48.5%），决赛巴西 vs 荷兰	德国（巴西半决赛 1-7 惨败）
2018	巴西夺冠（18.5%），决赛胜德国	法国（巴西八强出局、德国小组未出线）
2022	巴西 24% 居首，阿根廷 21% 第二	阿根廷（高盛给的是第二高）

印证其官方结论：再花哨的统计技术也难抵足球的内在不可预测性。

四、对比分析：我们 vs 高盛

4.1 相同点（殊途同归的共识）

两套系统由完全不同的团队独立搭建，却在几个根本选择上高度一致——这本身就是对这些方法的交叉验证：

1. 都把进球建模为泊松分布，且都是"先预测进球数，再二次推导胜平负 / 夺冠概率"，而非直接分类。
2. 都用蒙特卡洛模拟完整官方括号（我们 5k-10k 次，高盛 2026 用 5 万次），都严格套官方出线 / 平分规则。
3. 都强调"时间相关性"：高盛靠 Elo 递归更新 + 近 5/10 场动量窗口；我们靠指数时间衰减加权（half_life=730 天）。本质都是"近期比赛更重要"。
4. 都对友谊赛降权：高盛实证后直接排除友谊赛，我们把友谊赛权重降到 0.5——两边独立得出"友谊赛会污染信号"的同一结论。
5. 都做赛中滚动更新：真实赛果一出就回灌、重算下游概率。
6. 都对不确定性保持诚实：都公开承认足球本质难测，不吹"精准预测"。

4.2 各自优劣

● 我们的优势

- 完全透明可解释：每队仅两参数，任何预测可追溯，开源可复现、本地秒级运行。
- 严格回测纪律：每个改动必须用 RPS/LogLoss 数字证明更好才采纳（身价、Elo 集成都因此被否决）。
- 输出完整比分概率矩阵（11×11），不止胜平负——可读任意比分概率。
- DC 低分修正显式建模 0-0/1-1 平局相关，高盛泊松未提及此修正。
- 独有评级可信区间：贝叶斯分层给出 94% 可信区间——这恰恰是高盛不提供的。

● 我们的劣势

- 特征单一：只有历史进球数据，缺 Elo 动量、球员个体天赋、卫冕下滑、地理 / 海拔 / 温差等领域信息。
- 评级偏静态：单时点 GLM 拟合（虽用时间衰减近似），不如高盛 Elo 逐场递归更新动态。
- 无显式领域修正项（心态 / 回归均值等）。
- 赛事强度颗粒度粗：只分友谊 / 非友谊，未区分预选赛 vs 大赛。
- 淘汰赛平局用"热门方点球"近似，比高盛"烧抽样"略粗。

● 高盛的优势

- 特征丰富、领域知识深：Elo + 动量 + 球员天赋 + 心态 + 地理多维融合。
- Elo 递归更新更贴近实时实力变化。
- 赛制工程细致：5 万次模拟、495 种 R32 配对、烧抽样处理加时点球。
- 评估口径稳健：用"净胜球相关系数"+ 与博彩盘口对标，可跨年比较。
- 研究资源与品牌背书。

● 高盛的劣势

- 黑箱、不可复现：2018 ML 集成尤甚，外部无法验证 / 复跑。
- 战绩平平：连续三届（14/18/22）未押中冠军，自评相关系数仅 ~45—49%。
- 不给评级置信 / 可信区间，不输出完整比分矩阵。
- 重型：20 万模型 / 100 万模拟，对个人 / 实时场景不友好。
- 大量主观"领域修正项"有过拟合 / 人为偏见风险。

4.3 可借鉴之处：哪些已验证、哪些仍开放

核心原则不变：任何借鉴来的新特征 / 新机制，都要先在 `backtest.py` 里用 RPS 增益证明，否则不纳入。这恰是我们相对高盛"黑箱"的纪律优势。自上一版白皮书以来，原"待试清单"里多项已经用回测得出了结论：

1. **已实现** 升级评估口径：已在 RPS/LogLoss 之外加上"预测净胜球 vs 实际净胜球相关系数"（实测约 65%，高盛同口径指标）和"与博彩闭盘线对标 + CLV 检验"（`clv.py`，市场对标层），评估更稳健、可跨年横比。
2. **已否决** Elo 差作为 GLM 外生特征：按高盛"把 Elo 当核心协变量"的形式，在双泊松 $\log \lambda$ 里加一项 Elo 差重测过——RPS +0.0006 更差，`elo_coef` 为负：全套攻防 dummy 下 Elo 差冗余。`elo.py` 留作对照。
3. **已否决** 赛事强度分级加权：把"友谊 0.5 / 正式 1.0"细化为"友谊 / 预选赛 / 洲际杯 / 世界杯"多级权重回测过——全部更差（抬大赛权重 = 砍有效样本、升方差）；时间衰减已处理近期性，再细分洲际半衰期同样在 2026–06 sprint 里被否决。
4. **待试** 引入少量可解释领域修正哑变量（如"卫冕冠军下滑"、"对欧洲球队更难进球"）：仍开放，但每个都要单独回测、有 RPS 增益才留——把高盛的领域直觉，套进我们的回测纪律里。
5. **待试** 更细的在线更新：已做"刷新后自动全量 refit + 比赛日自动拉完赛"，可进一步借鉴高盛"逐比赛日 + Elo 增量"做更轻量的实时滚动。
6. **待试** 领域约束防极端值：高盛"得分天赋封顶 4 人"的思路，可用于未来任何球员级特征的稳健化处理（但无免费国家队 xG / 球员级历史源，目前是数据死胡同）。

小结：把高盛"领域知识显式编码"的思路套进我们的回测纪律后，能证明有效的极少——Elo、赛事分级、身价、负二项、后校准全部被数字否决，留下的每一项都有回测背书。这印证了正文反复出现的判断：在这套国家队数据上，纯 Dixon–Coles + 时间衰减已是扎实的局部最优。

五、结论

两套系统在泊松内核 + 蒙特卡洛模拟 + 友谊赛降权 + 滚动更新上殊途同归，验证了这条技术路线的合理性。高盛胜在特征工程的广度与领域深度，但以黑箱、重型、不可复现为代价，且战绩证明再多特征也跑不赢足球的随机性；我们胜在透明、可回测、可复现，并独有评级可信区间这一诚实的不确定性表达。最值得借鉴的不是高盛的某个具体特征，而是它"把足球领域知识显式编码"的思路——但我们要用自己的回测纪律去筛选，让每一个借鉴来的想法都经得起"用数字证明更好"的检验。这样既吸收其长，又不丢自己的根。

世界杯比分预测器 · 测算逻辑白皮书 (v3, 2026-06-29 修订) | 本文所有回测数字均可由 [backtest.py](#) / [bt_knockout.py](#)
/ [bt_calib_margin.py](#) / [bt_nbalph_scan.py](#) / [bt_rho_scan.py](#) 复现 (修复时间泄漏后的诚实口径) | 模型与代
码细节见项目 [CLAUDE.md](#) / [CHANGELOG.md](#)