



# 世界杯比分预测器 · 测算逻辑白皮书

Dixon-Coles 双泊松模型 × 蒙特卡洛赛事模拟 × 贝叶斯不确定性量化

—— 与高盛（Goldman Sachs）大赛预测方法论的对比分析

生成日期：2026-06-07 | 数据源：martj42 国际赛果（1872-2026） | 引擎经样本外回测验证

一句话概括：本系统把“预测一场球赛”拆成两层——先用 Dixon-Coles 双泊松回归从 150 年真实国际比赛数据里学出每支球队的进攻/防守强度，再用 10 万级蒙特卡洛模拟把单场概率滚成整届赛事的出线/夺冠概率。所有“优化”都必须通过样本外回测（RPS / LogLoss / 命中率）用数字证明更好才采纳，绝不凭感觉。

## 一、设计哲学：为什么这么建模

足球比赛的本质是低频泊松事件（进球稀少且近似独立），结果由两队的相对攻防实力加上不可消除的随机性共同决定。因此我们刻意选择一个可解释、可回测、训练秒级的统计模型，而非黑箱大模型：

- 可解释**：每支球队两个数字（进攻、防守），任何预测都能追溯到这两个系数，便于发现数据问题。
- 可回测**：模型轻，可在多个历史时段反复“只用过去预测未来”，量化真实预测力。
- 诚实的不确定性**：用蒙特卡洛与贝叶斯两条腿，分别量化“赛事随机性”和“评级估计误差”。

## 二、我们的测算逻辑（五层）



### 2.1 数据层：不是所有比赛都一样重要

原始数据为 martj42 公开数据集的 **results.csv**（约 4.9 万场国际比赛，1872 年至今）。关键在于**加权**——把每场比赛拆成“主队视角 / 客队视角”两行长表，每行配一个权重：

$$\begin{aligned} \text{weight} &= \text{时间衰减} \times \text{赛事强度} \\ &= 0.5^{(\text{比赛年龄\_天} / \text{half\_life})} \times (\text{友谊赛 } 0.5 / \text{正式赛 } 1.0) \end{aligned}$$

- 时间衰减**：半衰期 **half\_life=240** 天（≈8 个月）。一年前的比赛权重只剩约 1/3，三年前几乎归零——反映“国家队阵容和状态会换血”。
- 赛事强度**：友谊赛队伍不齐、强度低，权重下调到 0.5。
- 中立场处理**：世界杯多为中立场，主场优势只给真正的东道主（中立场两边 home=0）。
- 样本过滤**：最多回溯 16 年；出场不足 12 场的球队剔除（拟合不稳）。

经时间加权后，4.9 万场的“有效权重和”仅约 1519——这意味着真正主导评级的是最近一年多的比赛。这个数字在第 2.5 节解释可信区间为何偏宽时还会用到。

2.2 核心模型：Dixon–Coles 双泊松回归

每队单场进球数建模为泊松分布，进球期望  $\lambda$  由对数线性模型给出（Maher 1982 / Dixon–Coles 1997 的经典框架）：

$$\begin{aligned}\log \lambda_{\text{主}} &= \text{截距} + \text{主场优势} \cdot (\text{非中立}) + \text{进攻}[\text{主}] + \text{失球}[\text{客}] \\ \log \lambda_{\text{客}} &= \text{截距} + \text{进攻}[\text{客}] + \text{失球}[\text{主}]\end{aligned}$$

用 statsmodels 的 Poisson GLM 拟合（凸优化，秒级收敛），把上面的时间衰减权重作为 freq\_weights 喂入。每支球队最终得到两个系数：进攻强度（越高进球越多）与失球倾向（越负防守越好）。

Dixon–Coles 低分修正

独立双泊松会系统性低估 0–0、1–1 这类低比分平局（现实中两队都谨慎时强相关）。我们引入一个相关参数  $\rho$ ，只修正 (0,0)(0,1)(1,0)(1,1) 四个低分格，用一维优化单独估计：

$$\begin{aligned}\tau(0,0) &= 1 - \lambda\mu\rho & \tau(0,1) &= 1 + \lambda\rho \\ \tau(1,0) &= 1 + \mu\rho & \tau(1,1) &= 1 - \rho\end{aligned}$$

最终输出一个 11×11 的比分概率矩阵（0–10 球），归一化后即可读出：最可能比分、胜/平/负概率、期望进球 xG。

2.3 参数标定：用回测说话，不靠拍脑袋

这是本系统的纪律核心。任何参数改动都要在样本外回测里用数字证明更好。回测方法：选若干历史 cutoff，只用 cutoff 之前的数据训练，预测之后 270 天的真实比赛，比较预测的胜平负概率与真实结果。

| 指标                             | 含义                          | 方向   |
|--------------------------------|-----------------------------|------|
| RPS (Ranked Probability Score) | 有序三分类（主胜/平/客胜）的概率打分，足球预测金标准 | 越低越好 |
| LogLoss                        | 对数损失，重罚“自信却错”的预测            | 越低越好 |
| 命中率                            | 最大概率方向是否押中                  | 越高越好 |

实测证据（cutoffs = 2024–11 / 2025–08，horizon = 270 天，样本 n = 1399 场，本次现跑）：

| 配置                    | 样本 n | RPS ↓  | LogLoss ↓ | 命中率 ↑ |
|-----------------------|------|--------|-----------|-------|
| half_life = 547 天（旧）  | 1399 | 0.1474 | 0.7872    | 63.0% |
| half_life = 240 天（采纳） | 1399 | 0.1440 | 0.7745    | 65.2% |

240 天在三项指标上全面更优，因此采纳。同样的方法论让我们否决了两个看似合理的“优化”：

- 已否决

 身价先验：把评级向 Transfermarkt 阵容身价收缩——回测 RPS 无改善（国家队样本本就够大），默认关闭（身价数值仍在 UI 展示）。
- 已否决

 动态 Elo 集成：回测不如纯 Dixon–Coles，未启用，仅留作对照。

## 2.4 赛事蒙特卡洛模拟：从单场到夺冠

有了任意两队的比分概率，就能模拟整届世界杯。流程严格遵循 **2026 官方赛制**（12 组 × 4 队，32 队晋级含最佳第三名分配，官方淘汰赛括号槽位）：

1. **小组赛**：每场按比分概率分布**随机抽样**一个比分 → 算积分、净胜球、排名。
2. **出线**：每组前 2 + 成绩最好的 8 个第三名，按官方约束匹配到 R32 槽位。
3. **淘汰赛**：单场对阵按模型胜率推进，平局按热门方"点球"决出，直到冠军。
4. **重复 N 次**（默认 5000–10000）→ 统计每队的出线 / 八强 / 四强 / 决赛 / **夺冠概率**，并给出基于模拟的 95% 区间。

系统还提供**确定性投影**（project）：把已踢的真实赛果当事实锁定，未踢的取模型"最可能走势"，实时画出当前最可能的官方括号与冠军——支持用户改小组赛比分 / 录入或假设淘汰赛结果做 what-if，括号与夺冠概率即时重算。

## 2.5 贝叶斯分层评级：诚实回答"我们到底多确定"

蒙特卡洛量化的是**赛事随机性**，但还有一层不确定性被忽略了：**评级本身的估计误差**（数据有限，我们对"某队到底有多强"并不确定）。为此我们用 PyMC 搭了一个**分层贝叶斯双泊松模型**作为补充视图：

- 同样的加权泊松似然，但对攻防系数施加**分层正态先验**（部分汇合 partial pooling，非中心化参数化），NUTS 采样 ≈ 15 秒。
- 输出每队净实力的**后验分布**，从而得到 **94% 可信区间**。

**关键守则**：贝叶斯评级是**不确定性补充视图**，**不替换预测引擎**。预测与模拟仍由经回测验证的 Dixon–Coles 引擎驱动，未违反"改模型必须回测证明"的铁律。由于分层收缩 + 时间加权后有效样本仅 ~1519，可信区间普遍较宽且互相重叠——这是对"近 8 个月数据下顶尖球队统计上难分高下"的**诚实表达**，而非模型缺陷。

## 2.6 工程闭环：让预测随真实世界更新

### 实时赛果驱动

已踢的世界杯比赛=事实（蓝色锁定），其余按模型预测。一键"刷新真实赛果"拉取最新数据，并用**新数据重训评级**（自动 refit，≈9 秒）。

### 淘汰赛自动套入

已踢淘汰赛赛果按对阵**顺序无关**自动套进括号；平局的**点球胜者查 shootouts** 数据，解决官方比分库不记点球胜者的痛点。

### 赛果持久化

用户录入/假设的赛果**原子写入磁盘**，刷新或重启都不丢。

### 本地化体验

队名中文+国旗、北京时间 ↔ 场馆当地时间一键切换（104 场场馆时区经维基逐场核对）。

### 三、高盛（Goldman Sachs）的测算逻辑

高盛自 2010 年起发布《The World Cup and Economics》系列研究报告（由其 Global Investment Research 团队撰写）。下述事实主要取自 2018 与 2026 两版官方报告 PDF 原文，2022 细节取自 2026 报告中的官方回测段，2014 以报告转述为准。

一个反直觉但有据可查的事实：高盛只有 2018 一届真正用了机器学习集成（随机森林 + 贝叶斯岭回归 + Lasso + 梯度提升，20 万模型、100 万次模拟，自评比旧泊松回归准 5 倍）。但 2014 / 2022 / 2026 三届都是以 Elo 为核心的泊松回归——高盛试过 ML 之后又回到了 Poisson。

#### 3.1 模型与预测对象

与我们一致，高盛直接预测的是“每队每场进球数”，建模为泊松分布，胜平负 / 出线 / 夺冠概率全部由进球预测 + 模拟二次推导。2026 官方原文：“a regression model to predict the number of goals scored by a particular team ('team i') against a particular opponent ('team j')... described by a so-called 'Poisson' distribution.”

#### 3.2 特征工程：领域知识是其最大差异点

这是高盛与纯统计模型最不同之处——它往进球回归里塞了大量足球领域变量（以 2026 版最详尽）：

| 特征类别         | 具体内容                                                             |
|--------------|------------------------------------------------------------------|
| Elo 评分差（主驱动） | 赛前两队 Elo 之差；并随赛程递归更新。来源 eloratings.net。                          |
| 得分天赋         | 进入欧洲顶级联赛前 50 射手榜的本队球员数，每队封顶 4 人（防极端值）。来源 Transfermarkt。          |
| 动量 Momentum  | i 队最近 10 场正式赛进球数 + j 队最近 5 场正式赛失球数。                              |
| 心态 Mentality | 卫冕冠军下滑（winner's slump）、首次参赛超常发挥、对欧洲球队更难进球、足球强国“世界杯加成”——写进回归的哑变量。 |
| 地理 Geography | 主场效应、首都到赛地距离、低海拔国家在高海拔球场罚分、本国与赛地温差罚分。                            |

数据跨度：1978 年至今约 2 万场正式国际比赛；数据源 eloratings.net / Transfermarkt / FIFA。刻意排除友谊赛——2018 报告实证“加入友谊赛会让模型变差”。

#### 3.3 模拟、输出与自评

- 蒙特卡洛：2026 用 5 万次抽样（2018 曾用 100 万次）；每场从该对阵的泊松分布随机抽比分。严格套官方 FIFA 平分规则，处理 48 队赛制下 R32 的 495 种可能配对；淘汰赛若抽到平局则“烧掉该抽样”（burning draws），机械性让均值略高方胜出，近似加时 / 点球。
- 输出：每场最可能比分点估计 + 蒙特卡洛各轮 / 夺冠概率分布；赛中逐比赛日滚动重算。注意 不提供传统置信 / 可信区间。
- 诚实自评：2026 官方回测“预测净胜球 vs 实际净胜球的相关系数”——历届约 49%、2018 届 43%、2022 届 45%，自评“correlation remains modest”；并把自家概率与博彩盘口对标。

3.4 公开的"翻车"记录

高盛连续多届未押中冠军（且自己不回避）：

| 届次   | 高盛首选                        | 实际冠军               |
|------|-----------------------------|--------------------|
| 2014 | 巴西夺冠（给东道主 48.5%），决赛巴西 vs 荷兰 | 德国（巴西半决赛 1-7 惨败）   |
| 2018 | 巴西夺冠（18.5%），决赛胜德国           | 法国（巴西八强出局、德国小组未出线） |
| 2022 | 巴西 24% 居首，阿根廷 21% 第二        | 阿根廷（高盛给的是第二高）      |

印证其官方结论：再花哨的统计技术也难抵足球的内在不可预测性。

## 四、对比分析：我们 vs 高盛

### 4.1 相同点（殊途同归的共识）

两套系统由完全不同的团队独立搭建，却在几个根本选择上高度一致——这本身就是对这些方法的交叉验证：

1. 都把进球建模为泊松分布，且都是"先预测进球数，再二次推导胜平负 / 夺冠概率"，而非直接分类。
2. 都用蒙特卡洛模拟完整官方括号（我们 5k-10k 次，高盛 2026 用 5 万次），都严格套官方出线 / 平分规则。
3. 都强调"时间相关性"：高盛靠 Elo 递归更新 + 近 5/10 场动量窗口；我们靠指数时间衰减加权（half\_life=240 天）。本质都是"近期比赛更重要"。
4. 都对友谊赛降权：高盛实证后直接排除友谊赛，我们把友谊赛权重降到 0.5——两边独立得出"友谊赛会污染信号"的同一结论。
5. 都做赛中滚动更新：真实赛果一出就回灌、重算下游概率。
6. 都对不确定性保持诚实：都公开承认足球本质难测，不吹"精准预测"。

### 4.2 各自优劣

#### ● 我们的优势

- 完全透明可解释：每队仅两参数，任何预测可追溯，开源可复现、本地秒级运行。
- 严格回测纪律：每个改动必须用 RPS/LogLoss 数字证明更好才采纳（身价、Elo 集成都因此被否决）。
- 输出完整比分概率矩阵（11×11），不止胜平负——可读任意比分概率。
- DC 低分修正显式建模 0-0/1-1 平局相关，高盛泊松未提及此修正。
- 独有评级可信区间：贝叶斯分层给出 94% 可信区间——这恰恰是高盛不提供的。

#### ● 我们的劣势

- 特征单一：只有历史进球数据，缺 Elo 动量、球员个体天赋、卫冕下滑、地理 / 海拔 / 温差等领域信息。
- 评级偏静态：单时点 GLM 拟合（虽用时间衰减近似），不如高盛 Elo 逐场递归更新动态。
- 无显式领域修正项（心态 / 回归均值等）。
- 赛事强度颗粒度粗：只分友谊 / 非友谊，未区分预选赛 vs 大赛。
- 淘汰赛平局用"热门方点球"近似，比高盛"烧抽样"略粗。

### ● 高盛的优势

- 特征丰富、领域知识深：Elo + 动量 + 球员天赋 + 心态 + 地理多维融合。
- Elo 递归更新更贴近实时实力变化。
- 赛制工程细致：5 万次模拟、495 种 R32 配对、烧抽样处理加时点球。
- 评估口径稳健：用"净胜球相关系数"+ 与博彩盘口对标，可跨年比较。
- 研究资源与品牌背书。

### ● 高盛的劣势

- 黑箱、不可复现：2018 ML 集成尤甚，外部无法验证 / 复跑。
- 战绩平平：连续三届（14/18/22）未押中冠军，自评相关系数仅 ~45—49%。
- 不给评级置信 / 可信区间，不输出完整比分矩阵。
- 重型：20 万模型 / 100 万模拟，对个人 / 实时场景不友好。
- 大量主观"领域修正项"有过拟合 / 人为偏见风险。

## 4.3 可借鉴之处（借鉴思路，不抄实现，且必须过回测）

核心原则不变：任何借鉴来的新特征 / 新机制，都要先在 `backtest.py` 里用 RPS 增益证明，否则不纳入。这恰是我们相对高盛"黑箱"的纪律优势，借鉴时不能丢。

1. 把 Elo 差作为 GLM 外生特征再试一次。我们曾验证"Elo 集成"无增益，但高盛是把 Elo 当核心协变量而非事后集成——这是不同形式，值得用"在双泊松  $\log \lambda$  里加一项 Elo 差"的方式重测（项目已有 `elo.py` 可复用）。
2. 引入少量可解释领域修正哑变量：如"卫冕冠军"、"对欧洲球队"等。但每个都要单独回测，有 RPS 增益才留——把高盛的领域直觉，套进我们的回测纪律里。
3. 升级评估口径：除 RPS/LogLoss，增加"预测净胜球 vs 实际净胜球相关系数"和"与博彩盘口对标"两个 benchmark，让模型评估更稳健、可跨年横比。低成本高价值
4. 赛事强度分级加权：把现有"友谊 0.5 / 正式 1.0"细化为"友谊 / 预选赛 / 洲际杯 / 世界杯"多级权重，回测验证颗粒度收益。
5. 更细的在线更新：我们已做"刷新后自动全量 refit"，可借鉴高盛"逐比赛日 + Elo 增量更新"做更轻量的实时滚动。
6. 领域约束防极端值：高盛"得分天赋封顶 4 人"的思路，可用于未来任何球员级特征的稳健化处理。

## 五、结论

两套系统在泊松内核 + 蒙特卡洛模拟 + 友谊赛降权 + 滚动更新上殊途同归，验证了这条技术路线的合理性。高盛胜在特征工程的广度与领域深度，但以黑箱、重型、不可复现为代价，且战绩证明再多特征也跑不赢足球的随机性；我们胜在透明、可回测、可复现，并独有评级可信区间这一诚实的不确定性表达。最值得借鉴的不是高盛的某个具体特征，而是它"把足球领域知识显式编码"的思路——但我们要用自己的回测纪律去筛选，让每一个借鉴来的想法都经得起"用数字证明更好"的检验。这样既吸收其长，又不丢自己的根。